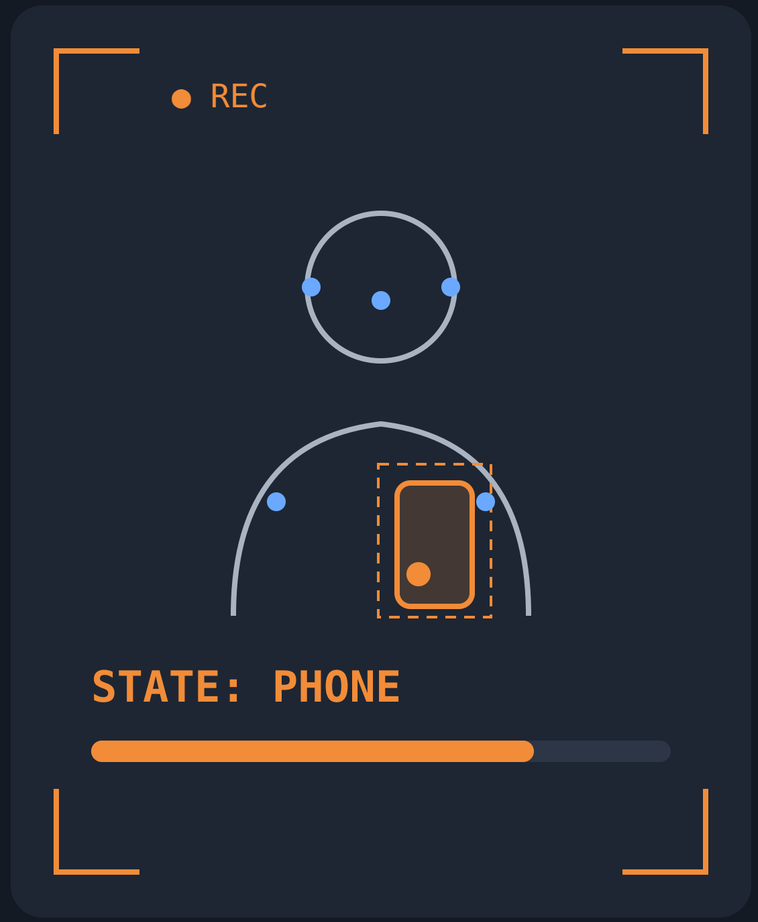
FINAL PROJECT · VISION-LLM MULTIMODAL SYSTEM

Focus Guard

“왜 집중 안 해?” 묻고, 변명까지 듣는 AI 공부 감독관



202439706 조예연 · 가천대학교 Physical AI · 2026.11.08

01 · 문제 정의

혼자 공부하면, 딴짓을 지적해 줄 사람이 없다

기존 방법

타이머 · 앱 차단

- 내가 실제로 무엇을 하는지 모른다
- 알림은 일방적이라 쉽게 무시된다
- 왜 집중이 깨졌는지 남는 기록이 없다

Focus Guard

보고, 묻고, 듣는다

- 카메라로 휴대폰 · 자세 · 시선을 인식
- “왜 집중 안 해?” 음성으로 직접 질문
- 내 변명을 듣고 타당한지 AI가 판단

02 · 시스템 개요

AI 감독관이 하는 일은 세 가지

STEP 1

본다

YOLO와 MediaPipe Pose로 휴대폰, 고개 방향, 자세를 매 프레임 인식

STEP 2

묻는다

이탈이 3초 이어지면 Gemma가 장면을 보고 “왜 집중 안 해?”라고 음성으로 질문

STEP 3

듣고 판단한다

Whisper로 변명을 듣고, Gemma가 타당한지 판단해 음성으로 답변

전체 파이프라인

① VISION — 매 프레임 (메인 루프)

카메라
Jetson CSI · GStreamer

▶

YOLO11n INT8
휴대폰 · 책 · 노트북 탐지

▶

MediaPipe Pose
손목 · 코 · 귀 · 어깨 랜드마크

▶

규칙 기반 판단
6가지 상태 + 지속 시간

▶

이벤트 발생
이탈 3초 지속 → ②로 전달

② LLM · 음성 — 이벤트 발생 시 (워커 스레드)

상태 JSON
→ 자연어 Context 변환

▶

Gemma 4 E2B
Context + 프레임 이미지 (mmproj)

▶

Piper TTS
“왜 집중 안 해?”

▶

Whisper STT
사용자의 변명 인식

▶

Gemma 판단
타당한가? → TTS로 답변

04 · 수업 내용 통합

섹션 2~6에서 배운 것을 하나로 연결했다

섹션	배운 것	프로젝트에서 사용
2 · Computer Vision	카메라 피드 · MediaPipe 신체 인식	CSI 카메라 + Pose 랜드마크로 자세 판단
4 · Object Detection	YOLO11n · TensorRT INT8 양자화	휴대폰 · 책 · 노트북 실시간 탐지
5 · LLM & Gemma	Gemma 4 · 프롬프트 설계	꾸짖기 · 변명 판단 · 리포트 프롬프트 4종
6-A · Vision-to-Text	YOLO → JSON → 자연어 Context	상태 JSON 저장 → 자연어로 Gemma에 전달
6-A · 파이프라인 분리	Vision과 LLM 실행 분리	카메라 루프와 LLM · 음성 스레드 분리
6-B · 멀티모달	이미지 + 텍스트 동시 입력	이탈 순간의 카메라 프레임을 함께 전달
6-C · STT / TTS	whisper.cpp · Piper	변명 듣기 · 음성으로 꾸짖기

여섯 가지 상태를 규칙으로 판단한다

FOCUS

집중

이탈 조건 없음. 책을 들고 고개를 숙이면 독서로 보고 집중 처리

PHONE

휴대폰 사용

휴대폰이 손목 근처에 있거나 사람 영역과 겹침

LOOKING_AWAY

딴 곳 보기

코가 귀 중심에서 크게 벗어나거나 한쪽 귀만 보임

HEAD_DOWN

졸음 의심

공부 물건 없이 코가 어깨선 가까이 내려옴

BAD_POSTURE

자세 흐트러짐

어깨선이나 양 귀를 잇는 선이 한쪽으로 기울어짐 (턱 괴기 등)

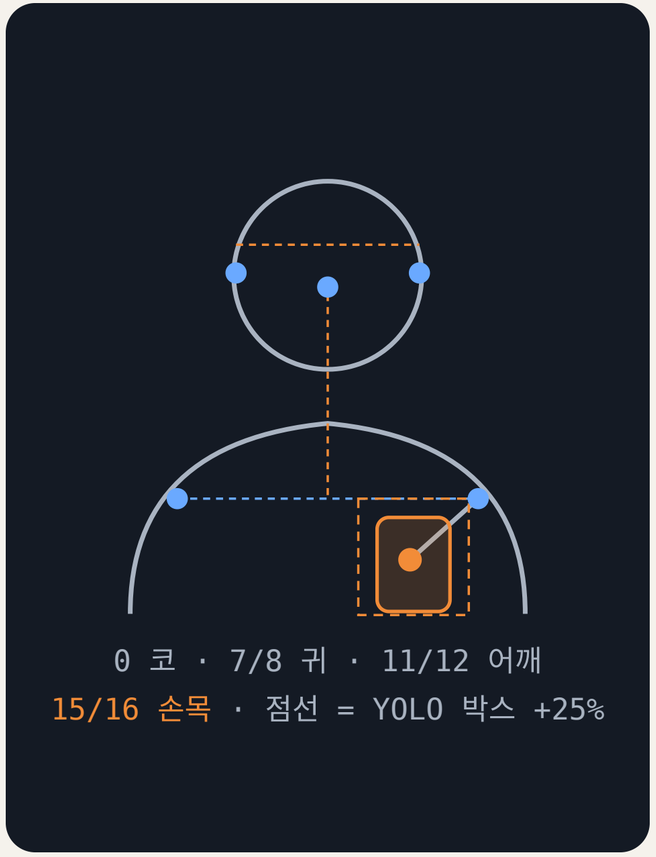
ABSENT

자리 비움

사람도, 자세 랜드마크도 탐지되지 않음

판단 우선순위 **자리 비움 → 휴대폰 → 딴 곳 보기 → 졸음 → 자세 흐트러짐 → 집중**

MediaPipe 랜드마크로 계산하는 네 가지 규칙



① 손에 든 물체

```
손목·검지(15,16,19,20) ∈ bbox × 1.25
```

YOLO 박스를 25% 넓혀서 손이 들어오면 HELD로 판단

② 고개 회전

```
|코x − 귀중심x| ÷ 귀 간격 > 0.35
```

또는 한쪽 귀만 보이면 고개를 돌린 것으로 판단

③ 고개 숙임

```
(어깨중심y − 코y) ÷ 어깨 너비 < 0.15
```

단, 책을 들고 있으면 독서로 보고 집중 처리

④ 자세 흐트러짐

```
어깨선 > 12° 또는 귀선 > 20°
```

두 점을 잇는 선의 기울기로 턱 괴기 · 삐딱하게 앉기를 감지

07 · 이벤트 트리거

순간이 아니라 ‘지속’될 때만 경고한다

3초

이탈 지속 시간

휴대폰 · 딴 곳 · 졸음 · 자세
흐트러짐이 3초 이어지면 경고. 화면 게이지로 표시

6초

자리 비움

잠깐 일어나는 건 봐주도록 기준을 더 길게

15초

경고 쿨다운

AI가 말하거나 듣는 중에는 새 경고를 만들지 않음

→ 잠깐 고개 돌린 것 같은 오탐과, 연속 잔소리를 함께 줄인다

08 · Vision → Text → Gemma

장면을 글로 바꾸고, 이미지와 함께 묻는다

Context — 상태 JSON → 자연어

현재 상태: 휴대폰 사용
손에 든 물체: cell phone
주변 물체: 없음
이 상태가 지속된 시간: 4초
공부 시작 후 경과 시간: 12.5분
지금까지 집중이 끊긴 횟수: 2번
전체 집중률: 81%

System Prompt — 꾸짖기

Instruction:
AI 공부 감독관으로서 집중하지 않는 이유를
지적하고, 왜 집중하지 않느냐고 물어보시오.

Constraint:
확인되지 않는 내용은 추측하지 마시오.
“왜”로 시작하는 질문을 반드시 포함하시오.

Output Format:
한국어 구어체 두 문장 이내.

+ 이탈 순간의 카메라 프레임 이미지를 함께 입력 (Gemma4ChatHandler · mmproj) · 숫자는 예시

09 · 변명 듣기

같은 질문, 변명에 따라 다른 대답

BAD_POSTURE · 타당한 이유

AI 감독관
자세가 많이 흐트러졌어요. 왜 그렇게 삐딱하게 앉아 있어요?

나
아 머리 아파서 잠깐 쉬는 거야

AI 감독관
그럼 5분만 쉬고, 물 한 잔 마신 다음 다시 시작해요.

PHONE · 핑계

AI 감독관
휴대폰 내려놓으세요. 왜 공부 안 하고 휴대폰 보고 있어요?

나
그냥 잠깐 인스타 봤어

AI 감독관
잠깐이 벌써 두 번째예요. 폰은 뒤집어 두고 다시 집중합시다.

* 예시 시나리오입니다. 실제 문장은 Gemma가 상황 정보와 이미지를 보고 매번 새로 생성합니다.

10 · 실시간 구조

AI가 생각하는 동안에도 화면은 멈추지 않는다

메인 루프 · 매 프레임

1. 카메라 프레임 읽기
2. YOLO 물체 탐지 + Pose 랜드마크 추정
3. 상태 판단 · 지속 시간 타이머
4. 화면 오버레이 (상태 · 게이지 · 집중률)

작업 큐

워커 스레드 · 이벤트 처리

1. Gemma 꾸짖기 → Piper 음성 출력
2. Whisper로 변명 녹음 · 인식
3. Gemma 판단 → 음성 답변
4. v 키: 음성 질문 · r 키: 공부 리포트

노트북에서 개발 → Jetson에서 실행 구성요소가 없으면 자동 대체: .engine → .pt · 멀티모달 → 텍스트 · STT → 키보드 · TTS → 콘솔

11 · 시연

직접 보여드리겠습니다

1

책을 들고 고개 숙이기

→ 집중 유지

2

휴대폰 들기

→ 3초 게이지 → 음성 경고

3

변명하기

→ Gemma가 판단해 대답

4

r 키

→ 오늘의 공부 리포트

한계와 다음 단계

한계

- 카메라가 정면 · 상반신을 봐야 정확함
- COCO에 펜 · 필기 클래스가 없어 필기 여부는 판단하지 못함
- 임계값이 사람 · 자세마다 달라 튜닝이 필요
- 엣지 기기에서 Gemma 이미지 추론은 응답 지연이 있음

확장

- 시작할 때 정자세를 측정하는 개인별 캘리브레이션
- 영유아 수면 안전 모니터: 얼굴 랜드마크가 사라지면 이불 덮임 경고 (같은 파이프라인)
- 공부 기록을 쌓아 주간 리포트 · 대시보드 제공

Q & A

감사합니다

Focus Guard — YOLO · MediaPipe · Gemma · Whisper · Piper on Jetson

202439706 조예연